Documento Técnico

Nombre: Roderick Espinoza

Pipeline de ingesta a BigQuery – ventas_mensuales

Objetivo

Construir un pipeline serverless en google que permita:

Recibir datos via http

Procesarlos en Python

Insertarlos en BigQuery

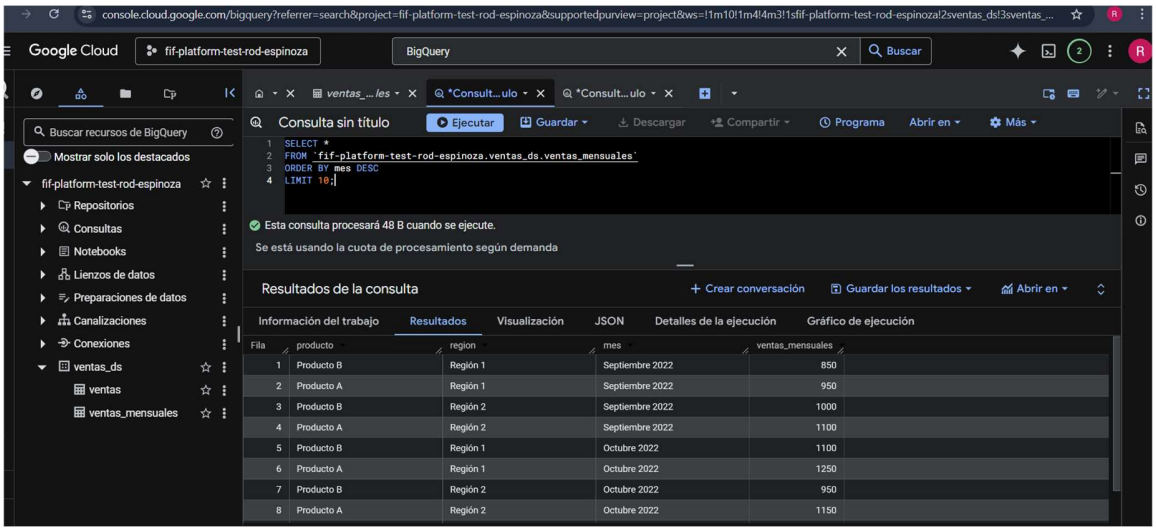

Proyecto Cloud

Proyecto: fif-platform-test-rod-espinoza

Servicio: Cloud Run (serverless)

Base de datos: BigQuery

Dataset, Table y Servicio Cloud Run

Dataset: Ventas_ds

Tabla: ventas_mensuales

Url Del servicio: https://ventas-service-489749636379.us-central1.run.app/

Arquitectura

Cliente (Powershell o Python) = > Cloud Run (Flask API) => Procesamiento (Python) =>BigQuery

Estructura del proyecto

App/main.py

/processor.py

/bigquery_client.py

/requirements.txt

/Dockerfile

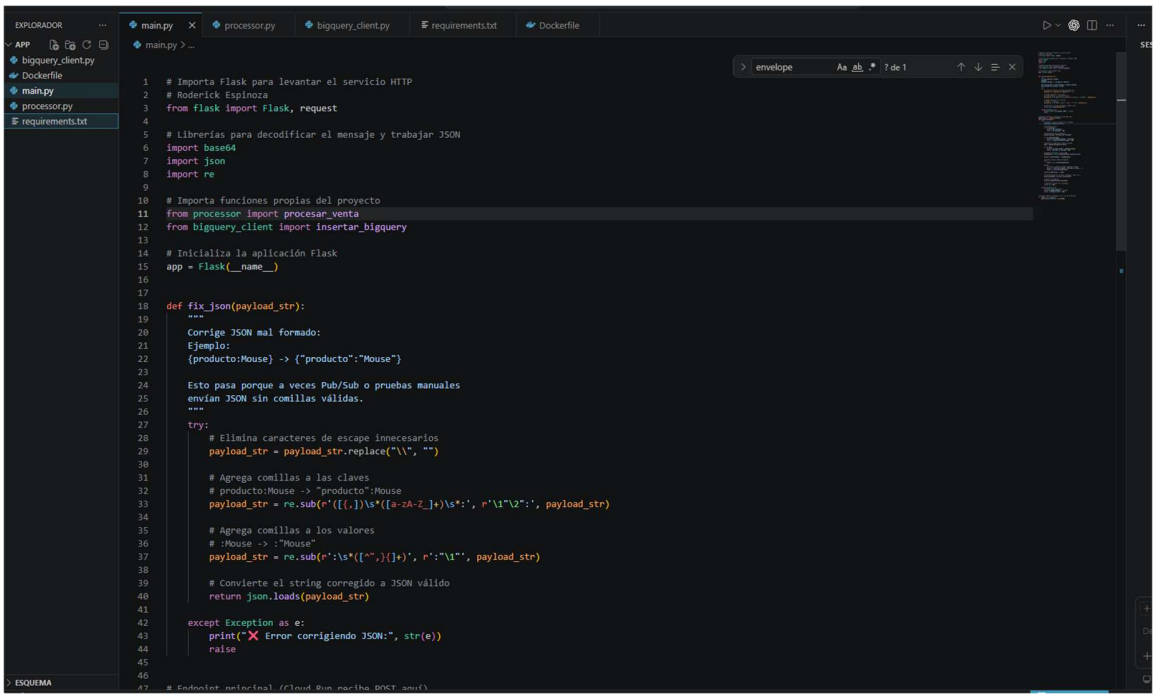

```python
# Importa Flask para levantar el servicio HTTP
# Roderick Espinoza
from flask import Flask, request

# Librerías para decodificar el mensaje y trabajar JSON
import base64
import json
import re

# Importa funciones propias del proyecto
from processor import procesar_venta
from bigquery_client import insertar_bigquery

# Inicializa la aplicación Flask
app = Flask(__name__)


def fix_json(payload_str):
    """
    Corrige JSON mal formado:
    Ejemplo:
    {producto:Mouse} -> {"producto":"Mouse"}

    Esto pasa porque a veces Pub/Sub o pruebas manuales
    envían JSON sin comillas válidas.
    """
    try:
        # Elimina caracteres de escape innecesarios
        payload_str = payload_str.replace("\\", "")

        # Agrega comillas a las claves
        # producto:Mouse -> "producto":Mouse
        payload_str = re.sub(r'([{,])\s*([a-zA-Z_]+)\s*:', r'\1"\2":', payload_str)

        # Agrega comillas a los valores
        # :Mouse -> :"Mouse"
        payload_str = re.sub(r':\s*([^",}{]+)', r':"\1"', payload_str)

        # Convierte el string corregido a JSON válido
        return json.loads(payload_str)

    except Exception as e:
        print("❌ Error corrigiendo JSON:", str(e))
        raise


# Endpoint principal (Cloud Run recibe POST aquí)
```

build

gcloud builds submit --tag gcr.io/fif-platform-test-rod-espinoza/ventas-app

Deploy

gcloud run deploy ventas-service --image gcr.io/fif-platform-test-rod-espinoza/ventas-app --platform managed --region us-central1 --allow-unauthenticated

prueba de envio

powershell:

Invoke-RestMethod -Uri "https://ventas-service-489749636379.us-central1.run.app/" -Method Post -ContentType "application/json" -Body (@{message=@{data=[Convert]::ToBase64String([Text.Encoding]::UTF8.GetBytes('{"producto":"Producto TEST","region":"Region TEST","mes":"Abril 2026","ventas_mensuales":999}'))}} | ConvertTo-Json -Depth 5)}'

Python: se va en repositorio de github un archivo **insertar.py**
https://github.com/respinozav/falabella

Looker Studio

URL: https://lookerstudio.google.com/reporting/046ec3f8-e963-424c-a64a-e43a27bb9e12

Y se comparte con las personas indicadas en el documento.

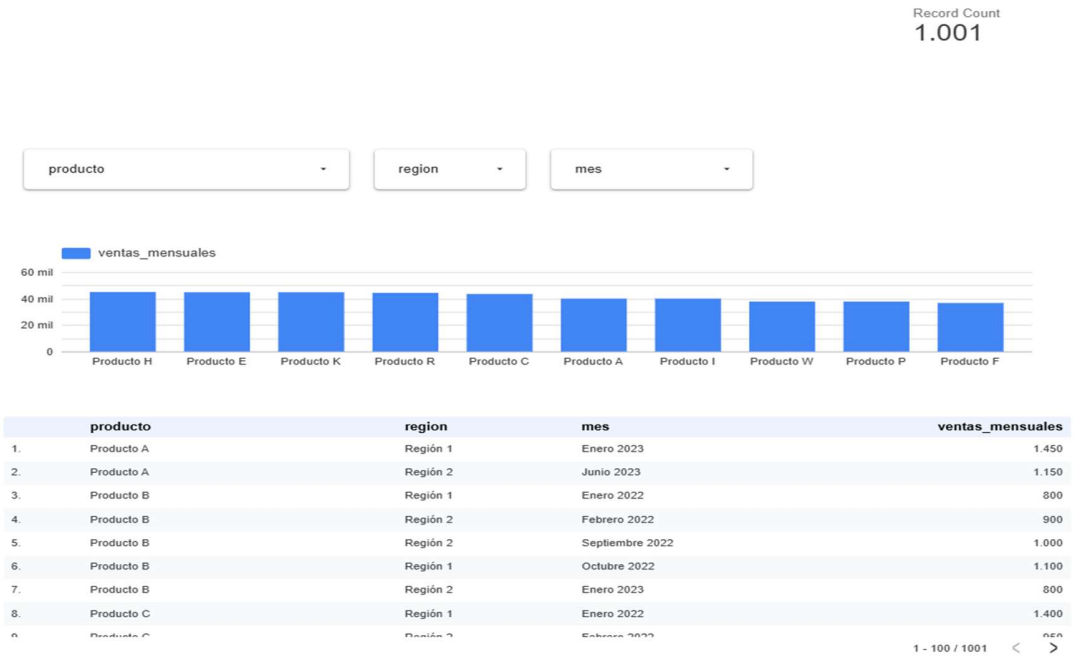

	producto	region	mes	ventas_mensuales
1.	Producto A	Región 1	Enero 2023	1.450
2.	Producto A	Región 2	Junio 2023	1.150
3.	Producto B	Región 1	Enero 2022	800
4.	Producto B	Región 2	Febrero 2022	900
5.	Producto B	Región 2	Septiembre 2022	1.000
6.	Producto B	Región 1	Octubre 2022	1.100
7.	Producto B	Región 2	Enero 2023	800
8.	Producto C	Región 1	Enero 2022	1.400

NOTA: en el documento se indica que se debe agrupar por departamento, pero en el csv no viene la columna departamento, por ende, se inserta un gráfico de barra por productos.

Preguntas de la Parte 2

1. Se tiene un pod dentro de un GKE el cual se tiene previsto que dentro de unos días realizará un alto consumo de recursos. El pod está dentro de un pool de nodos separado del principal. ¿Cómo es posible escalar el pod para que logre manejar el alto consumo? ¿Hay factibilidad de scale down?

Usar HPA (Horizontal Pod Autoscaler) para escalar réplicas según CPU/RAM o métricas custom.

Usar Cluster Autoscaler para agregar nodos al node pool si no hay capacidad.

Opcional: VPA para ajustar recursos del pod.

2. Para el mismo endpoint de la parte 1 de la prueba ahora se necesita restringir el acceso vía IAM de GCP. ¿Cuál o cuáles soluciones podrían utilizarse?

IAP (Identity-Aware Proxy) para proteger endpoint HTTP.

API Gateway + IAM (OAuth/JWT) para control de acceso por identidad.

Cloud Armor para control de IP + WAF.

Workload Identity para autenticación segura entre servicios.

3. ¿Cuáles son buenos criterios a la hora de escoger Serverless o VMs/K8S para un sistema?. De al menos 2 ejemplos

Serverless (Cloud Run/Functions): tráfico variable, microservicios simples, bajo mantenimiento.

Kubernetes/VMs: alta carga constante, sistemas complejos, control de red/infra.

Ejemplos:

Login API > Serverless

Sistema retail en cyberday > GKE

4. Usted está atendiendo a un cliente, el cual indica que un proceso de producción se ha caído. El cliente solo sabe que el proceso corre en la nube GCP en el proyecto proyecto-productivo-no-tocar. Indique los pasos que seguiría para determinar cuál es el problema y quién es el responsable del producto. Incluya las preguntas que le haría al cliente y las acciones técnicas

Revisar Cloud Logging / Monitoring

Revisar GKE: pods, eventos, restart, OOM

Revisar load balancer y dependencias (DB, APIs)

Revisar despliegues recientes

5. A usted le dan el requerimiento de disponibilizar un producto a los clientes, el cual está construido en una imagen de contenedor. Este producto debe estar disponible para una gran cantidad de clientes de forma concurrente, como un retail en cyberday ¿Qué tecnologías utilizaría para asegurar la disponibilidad? Considerar todo el ciclo de DevOps

GKE + HPA + Cluster Autoscaler

Cloud Load Balancer global

Cloud Armor (DDoS/WAF)

Cloud CDN

Memorystore (Redis) para cache

CI/CD: Cloud Build + Artifact Registry + GitOps (ArgoCD)

Observabilidad: Cloud Monitoring + Logging

6. ¿Qué recomendaciones y/o buenas prácticas seguiría para almacenar y consultar datos en BigQuery de tablas grandes para su uso en reportería?

Particionar por fecha

Clusterizar por columnas frecuentes

Evitar SELECT *

Filtrar siempre por partición

Usar materialized views

Separar capas: raw / curated / reporting

7. Utilizando la arquitectura de la parte 1, indique cuáles indicadores utilizaría para generar métricas y alertas significativas con el fin de asegurar la estabilidad y calidad de servicio (SLA)

CPU / memoria / nodos

Error rate (5xx)

Latencia p95/p99

Request rate (RPS)

CrashLoopBackOff / OOMKilled

Health checks del LB

SLA: disponibilidad y error budget burn rate

8. De la parte 1 de la prueba, ¿cuáles mejoras o oportunidades de implementación se podrían hacer utilizando IA?

Predicción de tráfico (autoscaling inteligente)

Detección de anomalías en logs/métricas

RCA automático de incidentes

Recomendación de optimización de costos (rightsizing)

Seguridad: detección de tráfico anómalo
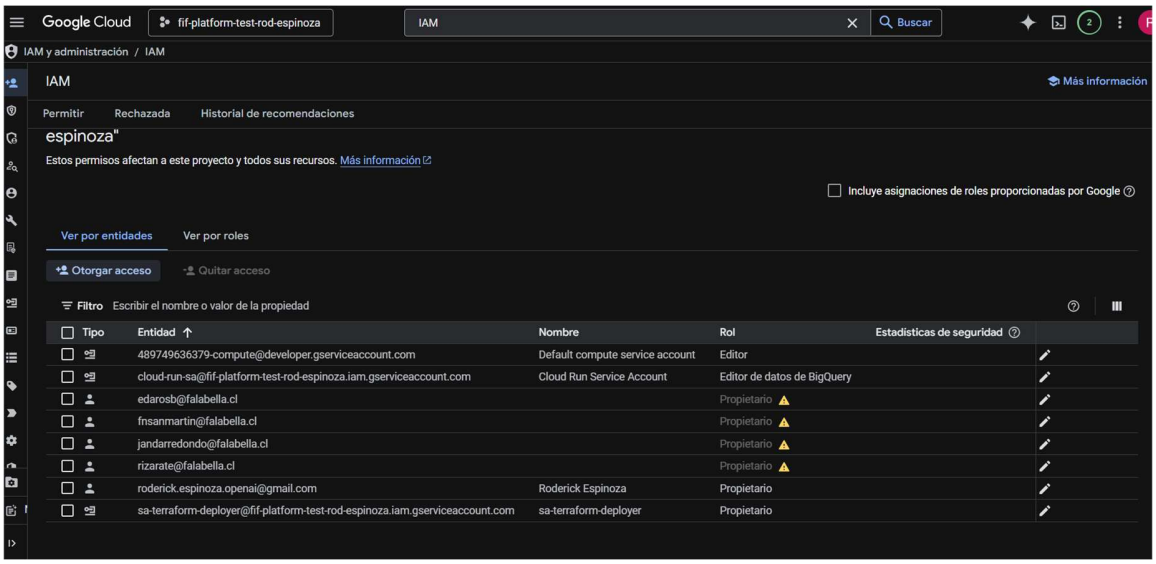
Se agregan como propietarios al proyecto los correos indicados.